

---

# 神经活动图像重建

---

王梓涵\*  
2020012715  
致理-信计01  
wangziha20@mails.tsinghua.edu.cn

王梓桥  
2020010923  
计03  
ziqiao-w20@mails.tsinghua.edu.cn

## 1 简介

我们的研究问题是神经活动图像重建：使用视觉皮层的神经元活动数据来反向重构动物的视觉影像。

近年来，对于视觉系统的研究越来越深入，随着神经科学研究成果的不断丰富，计算机视觉的研究热潮也渐渐兴起。在对大脑皮层进行研究后，我们发现大脑的不同区域在视觉处理中发挥着不同的功能：在视网膜接收刺激后，各个区域对神经信号进行层层编码，对特征进行提取，并在最终保存它们的高级特征，以供判断或其它功能。

本实验基于小鼠的v1视觉神经元。小鼠的视觉皮层以初级视觉皮层为主，结构简单，可以利用双光子成像技术采集小鼠观察不同自然图片的神经元活动情况。我们的实验目标是根据小鼠的若干v1神经元的反应值复现小鼠看到的图像，这对于解码视觉信息、探究视觉神经元运作机理有着重要意义。

现有方法集中在“根据图像预测神经元反应”[1][2]和“根据图像和反应计算神经元感受野”[3][4]这两部分，关于从神经元反应中重建图像的相关工作较少。经调研，预测神经元反应的深度模型可以被用在计算神经元感受野上，另外也可以使用Gabor函数拟合感受野，或者不使用感受野假设、直接利用Gabor Filter进行反应预测或图像重建。[5]

Gabor Filter:  $G(x) = \cos(2\pi f x \cdot u + \psi) e^{-((x \cdot u)^2 + \beta(x \cdot v)^2)/2\alpha^2}$

我们在已有工作的基础上，在用深度学习模型求出神经元MEI (Most Excited Inputs, 每个神经元的最能激发其反应的输入图像) 之后，尝试将原本用在Gabor Filter的加权平均方法迁移到MEI上，并将加权平均使用MLP、CNN等模型进行改进，发展了根据感受野复现图像的方法。此外，我们还尝试了不使用感受野假设、直接用生成模型从神经元反应中复现输入图像，取得了不错的效果。

## 2 相关工作

Edgar Y. Walker等人使用了sota模型deep CNN [6]求各个神经元的MEI (Most Excited Inputs)，并且比较了MEI与传统的Gabor-like感受野的不同，并证明了其在解码神经元反应方面的优越性。[1]

Takashi Yoshida等人使用了1248个Gabor Filter.[5]对于一张图片，使用线性回归模型将神经元对该图片的反应转换成各Gabor Filter的特征值，。即

$$F^j = H^j R + c^j$$

其中 $F^j = [F_{ji}]$ 表示第j个Gabor Filter的特征值，i表示第i张输入图片。 $H^j = [H_{jk}]$ 表示权重，k表示第k个神经元，j表示第j个Gabor Filter的权重。 $R = [R_{ki}]$ 表示神经元反应，k表示第k个神经元，i表示第i张输入图片。 $c^j$ 表示偏移量。

之后根据特征值对这些Gabor Filter进行加权平均求出重构图像 $I'$ ：

---

\*请将组长放到第一个位置

$$I' = G_{rev}F$$

这里利用了Gabor Filter 的almost self-inverting 性质，即在下列两式中：

$$F = G_{fwd}I \quad I' = G_{rev}F$$

$G_{fwd}$  和  $G_{rev}$  有如下关系：

$$G_{rev} = G_{fwd}^T = G_{fwd}^{-1}$$

即，可以通过训练一个根据输入图像利用Gabor Filter 预测神经元反应的模型，然后使用该模型的“逆”，结合Gabor Filter 和其特征值复现图像。

在我们的实验中，基于参考文献1的分析，使用参考文献4的加权平均方法并将其使用的Gabor Filter 置换为MEI 。

David A. Klindt等人采用了CNN模型预测神经元感受野[3]，其损失函数为

$$L = \frac{1}{B} \sum_{b,n} (y_{bn} - \hat{r}_{bn})^2 + \lambda_m \sum_{i,j,n} |m_{ijn}| + \lambda_w \sum_{k,n} |w_{kn}|$$

他们不仅求出了神经元感受野，还对神经元感受野的内容和其在输入图片中的位置进行了拆分与分析。在我们的实验中，在求得神经元的MEI 之后，也尝试用CNN 对各个MEI 作用的位置进行学习。

### 3 方法

我们的实验采用了两种不同的策略去完成任务，分别为“MEI加权求和法”与“条件GAN生成法”。这两种方法相互对照，可以体现出Conditional GAN在类似任务上的一些优势。

#### 3.1 MEI加权求和法

Edgar Y. Walker与Takashi Yoshida的工作为我们带来了灵感。一方面，既然可以将Gabor Filter加权平均求出重构图像[5]，若我们可以求出小鼠视觉神经的感受野，并对其进行加权求和，或许也可以对视觉影像进行复现。另一方面Edgar Y. Walker的工作展现了如何求出使神经元最为兴奋的输入MEI(Most Excited Inputs)[6]。因此，我们尝试将两种方法结合起来，以每个神经元对应的MEI作为小鼠视神经元的感受野的一种近似，同时通过各神经元的兴奋程度计算出权重，对所有MEI进行加权求和，从而恢复小鼠的视觉影像。

采用从神经元反应生成每个神经元的MEI (Most Exciting Inputs)，然后对于每张图片，将各神经元的MEI 与该神经元对这张图片的反应值进行加权平均得到重建的图片。即：

$$I_k = \frac{1}{n} \sum_{i=1}^n M_i * R_{ik}$$

其中 $I_k$  是第 $k$  张重建的图片， $M_i$  是第 $i$  个神经元的MEI， $R_{ik}$  是第 $i$  个神经元对第 $k$  张图片的反应值。

##### 3.1.1 MEI的生成

MEI 的生成采用github 开源项目FENS-2022 中提供的方法。首先训练出根据输入图像预测神经元反应的CNN 模型，然后随机生成一张尺寸(1,36,64) 的图片，以最大化神经元反应为目标，利用该CNN 模型进行1000 次迭代，得到该神经元的MEI 图像。下面是两个例子：

##### 3.1.2 模型架构

为此，我们构建了MLP与CNN结合的深度学习模型架构。首先，我们认为MEI的权重应该由小鼠的视觉神经元的兴奋程度决定。因此，我们设计了一个中间层有8192个神经元的MLP模型去完成这个从兴奋程度到感受野权重的映射。其次，由于生成的MEI相对于整张图片而言有效像素尺寸很小，并且存在中心偏移情况，我们希望通过一个CNN网络




Figure 1: MEI示例




Figure 2: MEI加权求和模型架构

对其进行处理，将其变换为比较理想的情况，从而更好地和MLP网络进行配合。最后，将每个感受野对应的权重与该感受野相乘，得到带权感受野，然后将各带权感受野进行累加，由5335个channel累加为与数据集中真实图片相同尺寸的1 channel图片，并与对应真实图片计算二范数Loss，从而对模型进行优化。

### 3.2 条件GAN生成法

由于该任务是从一个向量到一张图片的映射，我们认为使用生成模型是合适的。一方面，我们需要保证生成的图片足够真实；另一方面，我们也需要保证图片与该向量是对应的。因此我们选用了Conditional GAN架构来完成这两方面的任务[7]。

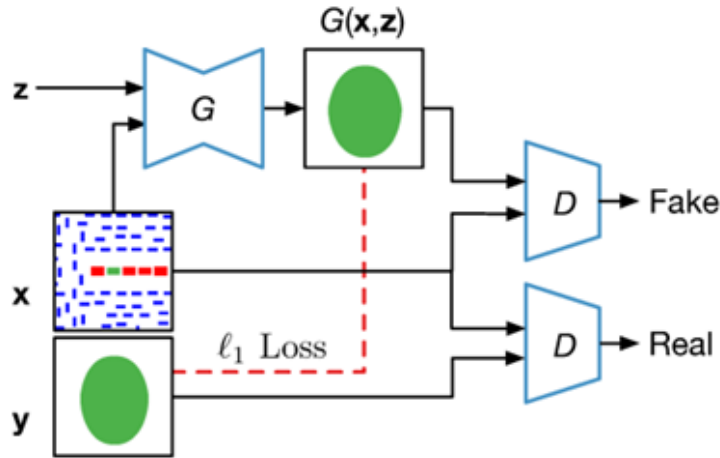


Figure 3: conditional GAN生成架构

我们的生成器通过反卷积——批标准化——激活函数组成的模块累积而成，将5335维度，通道为1的视神经响应向量映射为通道为1，尺寸为36\*64的生成图片。我们的判别器使

用CNN架构，目的是对生成图片与真实图片进行辨认，为真实图片打出尽可能高的分数，也为生成图片打出较低的分数，从而对生成器的训练产生推动作用。生成器需要尽力最大化判别器的评分，除此之外，还需要保证它根据输入向量生成的图片与真实图片较为符合，所以还需要最小化生成图片与真实图片之间的一范数Loss。对于判别器，它不仅要判断哪张是虚假的图片，哪张是真实的图片，同时也需要对条件——结果的匹配程度做出要求。因此我们自己在数据集中构建了一套响应与影响不对应的数据，训练判别器为其打出较低分数，而只在响应和真实图片相对应的时候才给出高分。

我们选择GAN的原因还有它对随机分布的引入[7]。它引入一个具有随机性的latent—— $Z$ ，为生成的图片赋予了更多的可能性。我们认为，相近的神经元反应可能并不对应完全相同的图片，真实的物体尽管存在颜色、外形上的细微差距，也可以产生类似的神经兴奋。因此，加入随机元素可以避免模型在不同的真实情况中左右为难，最终给出模糊的生成图片，相反地，通过 $Z$ 与判别器的配合，我们可以让生成器具有一定的创造力，并且较符合真实图片的特点。

## 4 实验

### 4.1 实验设置

#### 4.1.1 数据集

本次实验采用github 开源项目FENS-2022 提供的数据集，包括5993 张像素尺寸为(1,36,64)的图片，以及5335 个小鼠v1视觉皮层神经元对这些图片的反应值。反应值通过双光子成像方法采集得到。

数据集链接: <https://onedrive.live.com/download?cid=06D44059794C5B46&resid=6D44059794C5B46%21121992&authkey=AHJVfxtvAASasjQ>

图片示例:



Figure 4: 输入图片示例

#### 4.1.2 baseline设置

非深度学习方法: 给每个神经元拟合一个Gabor Filter形式函数的感受野，然后对所有感受野线性加权求和得到最终结果 (High-dimensional geometry of population responses in visual cortex) [5]

#### 4.1.3 baseline 结果

baseline方法带来的效果比较一般，我们从原文找到了一些结果的图片。




Figure 5: 复现图片 (左) 与真实图片 (右)

## 4.2 实验结果

### 4.2.1 MEI加权求和模型




Figure 6: MSE Loss训练曲线

我们画出了MLP与CNN结合模型在训练过程中的Loss曲线，事实上，对于每张图片，它的MSE Loss在训练后期逐步收敛到3000的水平上。对于36\*64大小的图片，在这样的误差水平上，我们是期望它可以有一些图案显示的。但是，我们得到的结果难以分辨，如图所示。




Figure 7: 复现图片（左）与真实图片（右）

对于这样的结果，我们总结了如下的原因：

- 神经元对图像的反应可能不完全是线性关系的，神经元与神经元之间会产生相互的作用，并且高级神经元的反应是低级神经元的抽象。因此，简单地将所有神经元的感受野进行加权平均是不合适的，在没有考虑相互作用以及层次关系的情况下，这样的模型架构难以复原出好的图像。
- MEI与感受野的关系有待商榷。MEI是对神经元刺激性最强的影像输入，但感受野一般指的是神经元对影像进行特征提取的一种偏好，是否可以用MEI在该实验模拟感受野的近似需要更强大的科学依据。
- MEI的实现是对模拟神经元的CNN进行类似对抗攻防的对输入求导运算所得到的，经过模拟神经元的CNN，又经过求导优化过程，再经过我们制作的深度神经网络，误差将一步步累积，在低维空间的细微误差往往导致在高维空间的严重差距，因此，误差的累积也是原因之一。
- 受计算资源的限制，我们只能实现非常简单的MLP与CNN架构，否则会超出显存最大值，模型架构的简单可能导致欠拟合。

## 4.2.2 Conditional GAN




Figure 8: GAN训练曲线

如训练曲线所示，在判别器和生成器上，我们选用的Loss都得到了比较好的下降和收敛。事实上，利用反卷积架构的生成器与卷积架构的判别器，该对抗生成网络的确为我们带来了惊喜。在我们看来，无论是对MEI加权求和的方式，还是baseline中使用Gabor Filter的加权方式，都没能呈现很好的效果。但使用了GAN的生成架构，可以做到对原图片程度相当的复原(figure9)。

不过我们也发现了一些不是很令人满意的结果，有一些图片非常得模糊，还有一些图片人眼无法分辨类别(figure10)。我们对该模型的优点和缺点总结了以下的原因：

- 生成器的反卷积架构将输入的神经响应向量进行处理，首先经过一个线性结构处理为多个channel的向量，然后利用卷积核对多个channel同时进行反卷积，在反卷积操作时，channel之间的关系被自然而然地考虑到，再经过多次这样的反卷积和激活函数操作，可以为输出添加较好的非线性特质，可能在这个过程中就将高层神经元和低层神经元的特质进行了分离，这样的架构兼顾了层级与相互作用。
- GAN的判别器可以很好地为生成器提供标准，这种标准是无法用简单的loss函数去刻画的。通过匹配、真实两个维度的要求，判别器将生成器训练为灵活的、有随机性创造力的图片生成者，生成器也成功生成了我们想要的对应图片。
- GAN并未使用MEI或者手工拟合的感受野，因此不会继承上层工作的误差。
- GAN本身比较难训练，不稳定，并且该任务并非特定类别的生成，而是对多种多样事物的预测。因此我们任务预训练可以提高GAN的性能，使其在大多数类别上有所进步。
- 数据集本身分辨率非常低，有些图片我们人工也无法辨认。由于数据集的限制，生成图片较为模糊。
- GAN的结构较为简单，由于神经网络总是倾向于学习低频率的信号特征，缺少对高维信号的拟合，因此生成的图片会遇到轮廓鲜明但细节较差的情况。




Figure 9: 复现图片（左）与真实图片（右）




Figure 10: 不好的结果

## 5 总结

我们的工作神经活动图像重建上取得了一定程度的成果，目前可以使用小鼠视觉皮层的神经元活动数据来反向重构视觉影像。现有的方法大多基于拟合感受野，然后将感受野变换为视觉影像。在本次研究中，我们首次实现了生成模型在该方面工作的应用，并且不需要提前通过人工或是深度学习的方式去拟合感受野。并且，我们复现了利用深度学习拟合小鼠的MEI的工作成果，成功通过输入图片和神经响应构造了模拟神经元的CNN模型，对该模型的输入进行优化后，得到使神经元最大兴奋的输入影像。

工作的结果显示视觉神经的工作方式并不像我们想象的那样简单，其工作行为并不是简单的线性累积，而是在相互作用和层次结构下产生非线性关系，将特征一步步提取到脑的高级处理区。我们对脑的工作方式认知依然短浅，对神经工作方式的研究仍需深入。

在未来，我们的工作可能是为GAN进行预训练，使其对更多的类别有所准备；同时改进它的架构，使其对图片细节有更好的处理。另外，由于GAN本身有输入分离的特性，我们可以尝试对输入的神经向量中某一神经元的数值做插值分析，查看这样会对输出的影响产生何种影响，从而分析该神经元在视觉行为中的作用。

## 6 代码链接

[https://github.com/ziqiao-w/ANN\\_homework](https://github.com/ziqiao-w/ANN_homework)

## 参考文献

### References

- [1] Walker, E. Y., F. H. Sinz, E. Cobos, et al. Inception loops discover what excites neurons most using deep predictive models. *Nature neuroscience*, 22(12):2060–2065, 2019.
- [2] Sinz, F., A. S. Ecker, P. Fahey, et al. Stimulus domain transfer in recurrent models for large scale cortical population prediction on video. *Advances in neural information processing systems*, 31, 2018.
- [3] Klindt, D., A. S. Ecker, T. Euler, et al. Neural system identification for large populations separating “what” and “where”. *Advances in Neural Information Processing Systems*, 30, 2017.
- [4] Stringer, C., M. Pachitariu, N. Steinmetz, et al. High-dimensional geometry of population responses in visual cortex. *Nature*, 571(7765):361–365, 2019.
- [5] Yoshida, T., K. Ohki. Natural images are reliably represented by sparse and variable populations of neurons in visual cortex. *Nature communications*, 11(1):1–19, 2020.
- [6] Cadena, S. A., G. H. Denfield, E. Y. Walker, et al. Deep convolutional models improve predictions of macaque v1 responses to natural images. *PLoS computational biology*, 15(4):e1006897, 2019.
- [7] Mirza M., O. S. Conditional generative adversarial nets. 10.48550/arXiv.1411.1784, 2014.